Proposta de robô com **aprendizado de máquina**

Cata-vento Seletivo

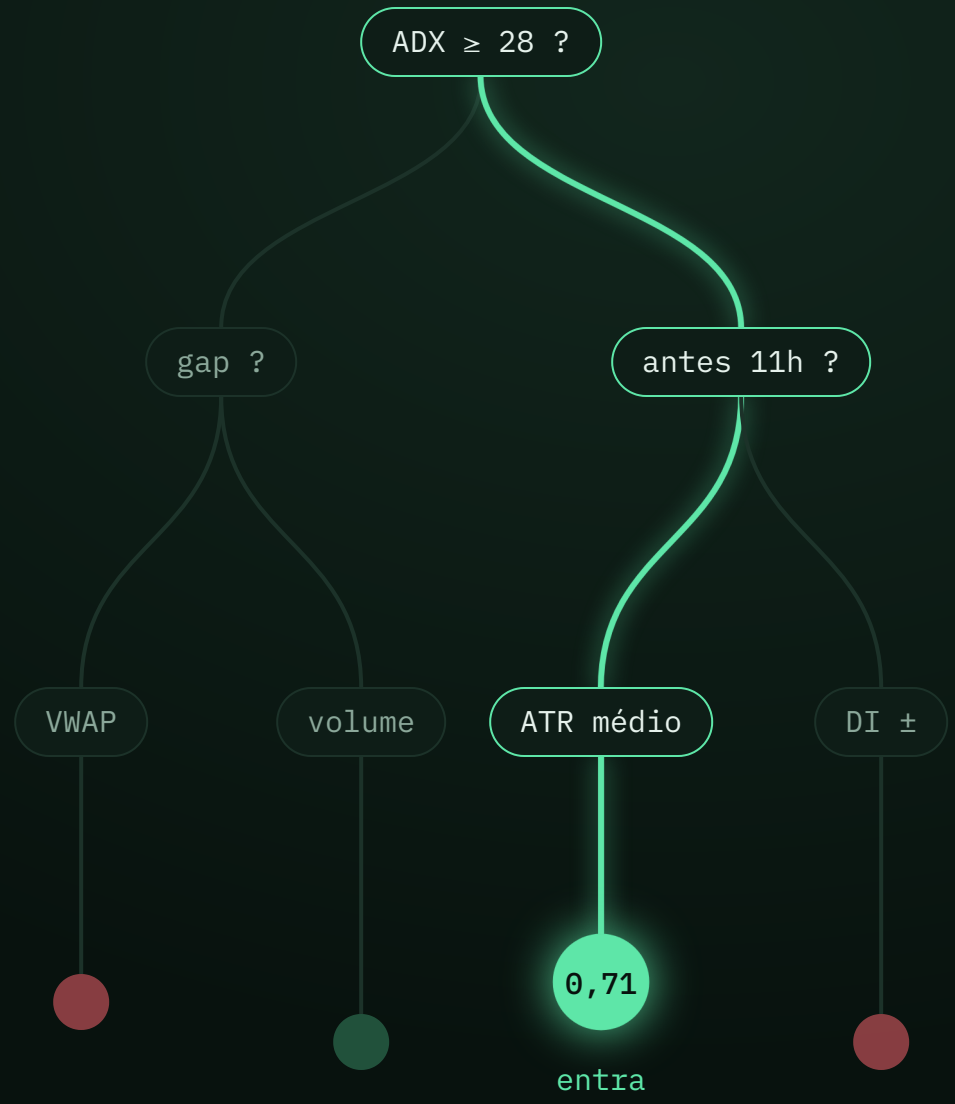
Robô de day trade no Mini Índice. A regra do DMI/ADX propõe a entrada e uma floresta de 300 árvores de decisão estima se ela vale a pena.

Integrantes
Luisa Caetano Araujo Raíssa

Professor
Alexandre Pimenta

Técnica
Random Forest

WIN$ · 15 minutos · B3
Modelagem e Projeto de Algoritmos para o Mercado Financeiro



A mesma regra acerta num dia e erra no outro

Um sinal de DI com ADX forte às 10h, logo depois de um gap, não é o mesmo sinal às 16h num dia parado. A regra fixa trata os dois igual. O objetivo é um robô que **aprende com o histórico em que contexto o sinal funciona** e só opera esses.

contexto

O sinal depende do momento

Horário, volatilidade e distância da VWAP mudam a chance de a mesma entrada dar certo.

não linear

Ninguém escreve essas regras à mão

"ADX alto só ajuda com volatilidade média" é o tipo de interação que uma árvore de decisão encontra sozinha.

regime

O mercado muda

O que separava sinal bom de ruim em 2024 pode não valer em 2026. Por isso o modelo é retreinado todo mês.

vantagem competitiva

Menos operações ruins: o filtro descarta os sinais de baixa probabilidade e deve **subir o fator de lucro e baixar o rebaixamento**, operando menos. A base já tem vantagem medida: fator 1,36 em 533 operações no Trabalho 01.

oportunidade de mercado

O Mini Índice é um dos contratos mais líquidos da B3. Vale **R$ 0,20 por ponto**, tem margem baixa e movimentos intradiários direcionais frequentes. Como é day trade, não há risco de gap noturno.

A regra propõe. A floresta decide.

A regra é a do Cata-vento do Trabalho 01, mais permissiva de propósito (ADX ≥ 20, não 25), para gerar candidatos em excesso. A seleção fina fica com o modelo.

entrada · lida só na barra fechada de 15 minutos

Candidato de compra	`DI+ > DI−` e `ADX ≥ 20` e `ADX subindo`
Candidato de venda	`DI− > DI+` e `ADX ≥ 20` e `ADX subindo`
Filtro do modelo	Entra só se `P(alvo antes do stop) ≥ p*`
Filtros operacionais	Entre 09:15 e 17:00, sem posição aberta, limites do dia livres

indicadores

DI+ / DI− (12)	direção
ADX (12)	força
ATR (14)	volatilidade: escala stop e alvo
VWAP do dia	contexto para o modelo

O DMI 12 fica fixo porque o Trabalho 01 mostrou que ele não decide o resultado: **de 8 a 20, o fator de lucro ficou entre 1,24 e 1,42**, sete de sete. O aprendizado vai para onde há ganho, que é escolher os sinais.

Quatro saídas, todas medidas em ATR

saída · com justificativa

Stop loss	1,5 × ATR	Múltiplo do ruído do dia: não fica curto em dia agitado nem largo em dia calmo.
Take profit	3,0 × ATR	Relação 2:1. Acertar mais de 1/3 já cobre as perdas antes dos custos.
Zero a zero	1,5 × ATR	Stop vai para a entrada. No Trabalho 01, levou o fator de 1,26 para 1,34.
Encerramento	17:30	Day trade: nada atravessa o pregão.

tamanho de posição · risco fixo, ajustado pela confiança do modelo

```
contratos = ⌊ R × Capital ÷ (1,5 × ATR × R$ 0,20) ⌋
entre 1 e 5 contratos
```

p* ≤ P < 0,65	R = 0,25%	confiança moderada
P ≥ 0,65	R = 0,50%	confiança alta, risco cheio

Volatilidade sobe, o stop alarga, o número de contratos cai. **O risco em reais fica constante.**

uma por vez

Só uma posição aberta. Sem pirâmide, sem preço médio.

trava do dia

No máximo 4 operações. Para após –1,5% do capital ou 3 stops seguidos.

proteção no servidor

Toda ordem sai com stop e alvo. Se a conexão cair, a proteção continua.

Aprendizado de máquina · **técnica escolhida**

Por que Random Forest

O problema é de **classificação**: dado o contexto no momento do sinal, a operação bate o alvo antes do stop? São 300 árvores de decisão, cada uma treinada numa amostra diferente dos dados, e a resposta é a média das estimativas delas.

comparação com as outras técnicas permitidas

	poucos dados	treino	explicável	usa o contexto
Random Forest	bom	segundos	sim	sim
Rede LSTM	fraco	lento	não	sim
Algoritmo Genético	bom	horas	sim	não
Lógica Fuzzy	bom	rápido	sim	regras à mão

o que pesou na escolha

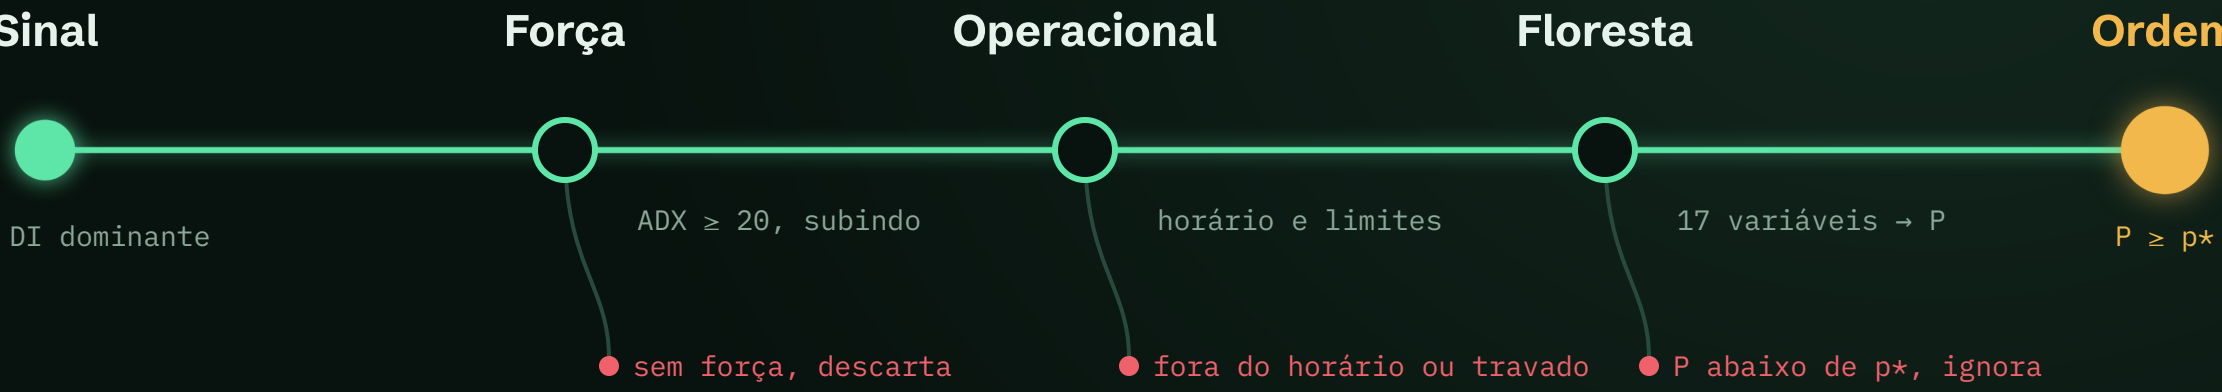
Seis meses dão algumas centenas de sinais. A floresta lida bem com isso. Uma LSTM decoraria ruído.

A média de árvores diferentes reduz o sobreajuste de uma árvore isolada.

A importância das variáveis mostra o que pesa na decisão.

Implementação direta: `scikit-learn` em Python, com exportação para ONNX e execução no MetaTrader 5.

Só vira ordem o que sobrevive às quatro etapas



como a floresta chega em P

Cada árvore faz perguntas sobre as variáveis (`ADX ≥ 28?`, `antes das 11h?`, `ATR alto?`) e termina numa folha. A folha guarda a proporção de operações do treino que bateram o alvo. **P é a média dessas proporções nas 300 árvores.**

exemplo · sinal de compra às 10:45

Média das 300 árvores	0,71
Limiar p* do mês	0,60
Decisão	entra, risco 0,50%

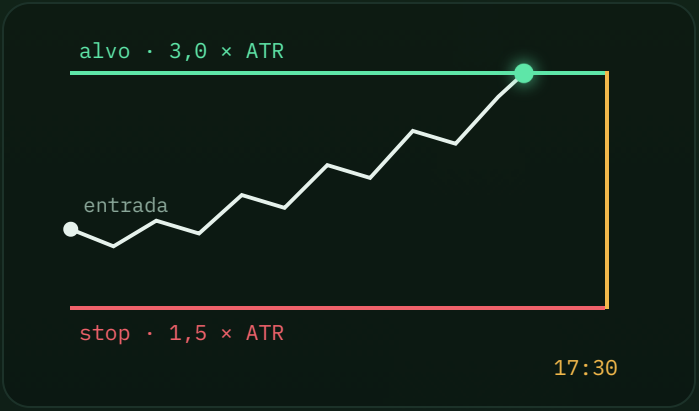
Variáveis de entrada e rótulo

features · calculadas na barra do sinal, só com o passado

Tendência	ADX, inclinação do ADX em 3 barras, DI+ − DI− no sentido da operação
Volatilidade	ATR ÷ preço, percentil do ATR em 20 pregões, amplitude do dia em ATRs
Momento	Retorno das últimas 1, 4 e 16 barras, em ATRs
Posição no dia	Distância à VWAP, posição na máxima e mínima do dia, gap de abertura
Fluxo	Volume da barra ÷ média do mesmo horário em 20 pregões
Calendário e sinal	Minutos desde a abertura, dia da semana, sentido, operações já feitas no dia

Tudo que tem direção é multiplicado pelo sentido (+1 compra, −1 venda). Assim **"a favor" significa o mesmo nos dois lados**, e um único modelo serve para compra e venda.

rótulo · método das três barreiras



Cada sinal do histórico é simulado com **as mesmas saídas do robô**, inclusive a trava no zero a zero.

y = 1 se sai no alvo.
y = 0 se sai no stop, no zero a zero ou às 17:30.

Acurácia não paga conta. Fator de recuperação, sim.

o que se pretende otimizar

A seleção das operações: P(y = 1 | contexto).

O limiar p*: de 0,40 a 0,70, em passos de 0,025.

Hiperparâmetros: profundidade {3, 5, 8}, mínimo por folha {5, 10, 20}, variáveis por divisão {√p, 0,5}. 300 árvores, classes balanceadas.

função objetivo

```
F = Lucro ÷ Rebaixamento
operações filtradas da
validação, com custos
```

As árvores minimizam a impureza de Gini. A escolha de hiperparâmetros e limiar usa o **resultado em reais**, porque um modelo pode acertar muito e ainda perder dinheiro.

Custos: R$ 0,50 por contrato por lado, mais 1 tick de derrapagem.

restrições

Mínimo de 20 operações e fator de lucro ≥ 1,05 na validação. Se violar, F = –1.

Sem olhar o futuro: só barras fechadas e validação sempre depois do treino, sem embaralhar a ordem.

Sem vazamento de rótulo: toda operação fecha até as 17:30, então nenhum rótulo do treino depende de dados da validação ou da execução.

Day trade, uma posição por vez, no máximo 4 operações por dia.

As regras de DMI/ADX e as saídas em ATR **ficam fixas**. Otimizar a regra e o filtro ao mesmo tempo mudaria o rótulo a cada tentativa e multiplicaria o risco de sobreajuste.

Arquitetura temporal · **janela móvel**

Treina no passado, opera o mês seguinte, repete



120
pregões de treinamento

20
pregões de execução

~40
ciclos fora da amostra

2023-26
WIN$ M15, ~940 pregões

No Trabalho 01 **não houve teste fora da amostra**: o WINV26 vence e a corretora não mantém os contratos vencidos. A série contínua `WIN$` resolve isso, e cada mês operado é um mês que o modelo nunca viu.

Como vamos saber se funcionou

só o resultado fora da amostra conta, comparado com

Regra sem filtro	Todos os sinais operados. Isola o valor do Random Forest.
Cata-vento original	O robô do Trabalho 01, com parâmetros fixos.

Métricas: lucro líquido, fator de lucro, rebaixamento, fator de recuperação, acerto, número de operações e AUC.

A hipótese se confirma se o filtro superar a regra sem filtro em fator de recuperação na maioria dos ciclos. Se não superar, isso também é resultado, e será relatado.

plano de implementação

- **Dados**
  Exportar as barras M15 do WIN$ do MetaTrader 5 para CSV.
- **Sinais, variáveis e rótulos**
  Python com pandas: regra do DMI/ADX, 17 variáveis e os rótulos.
- **Laço walk-forward**
  scikit-learn: treino, validação, limiar e execução, ciclo a ciclo.
- **Relatório e demonstração**
  Curva fora da amostra e comparação. Opcional: modelo em ONNX rodando no MT5.

Cata-vento Seletivo · WIN$ · B3

Agradecemos a atenção

Ficamos à disposição para as perguntas.

Integrantes
Luisa Caetano Araujo
Raíssa

Professor
Alexandre Pimenta

Modelagem e Projeto de Algoritmos para o Mercado Financeiro · Ciência da Computação

