PROPOSTA DE TRABALHO · MODELAGEM E PROJETO DE ALGORITMOS PARA O MERCADO FINANCEIRO

Cata-vento Seletivo

Robô de day trade no Mini Índice que usa Random Forest para escolher quais sinais operar, com retreino em janela móvel

4.1 Título e identificação

Título	**Cata-vento Seletivo**: robô de day trade no Índice Futuro (WIN) com filtro de sinais por Random Forest retreinado em janela móvel (*walk-forward*)
Integrantes	Luisa Caetano Araujo · RA _____ Raíssa _____ · RA _____
Disciplina	Modelagem e Projeto de Algoritmos para o Mercado Financeiro
Professor	Prof. Alexandre Pimenta
Data de entrega	___/___/2026
Etapa	Proposta conceitual e metodológica, sem implementação de código

4.2 Objetivo e justificativa

Objetivo específico do robô

Operar day trade no **Mini Índice Futuro da B3** (série contínua `WIN$` no backtest), no tempo gráfico de **15 minutos**. Uma regra de seguimento de tendência baseada no **DMI/ADX** gera os *candidatos* a entrada. Um classificador **Random Forest** estima, para cada candidato, a probabilidade de a operação atingir o alvo antes do stop, e o robô só entra quando essa probabilidade passa de um limiar p^*. O modelo é **retreinado todo mês** com os seis meses de pregões imediatamente anteriores.

Por que usar Aprendizado de Máquina

- **A mesma regra acerta em um contexto e erra em outro.** Um cruzamento de DI com ADX forte às 10h, logo após um gap, não é o mesmo sinal que o cruzamento às 16h num dia sem volatilidade. Uma regra fixa trata os dois igual. O modelo aprende, a partir do histórico, em quais contextos o sinal funciona.
- **As interações são não lineares.** "ADX alto só ajuda quando a volatilidade é média" é o tipo de condição que ninguém escreve à mão, mas que uma árvore de decisão encontra sozinha.
- **O mercado muda de regime.** O que separa sinal bom de sinal ruim em 2024 pode não valer em 2026. Retreinar em janela móvel mantém o modelo atualizado.

Vantagem competitiva esperada

- **Menos operações ruins.** A regra base gera sinais em excesso de propósito. O filtro descarta os de baixa probabilidade, o que deve subir o fator de lucro e reduzir o rebaixamento, mesmo operando

menos.

- **Base com vantagem medida.** A regra de entrada vem do robô *ADX Cata-vento* (Trabalho 01), que obteve fator de lucro de 1,36 em 533 operações no WINV26. O ML refina uma estratégia que já tem resultado, em vez de procurar uma do zero.
- **Validação honesta.** No Trabalho 01 não houve período fora da amostra, porque o contrato vence e o histórico some. A série contínua `WIN$` permite dezenas de meses fora da amostra.
- **Decisão explicável.** A importância das variáveis mostra o que o modelo está usando. Se ele passar a depender de algo sem sentido econômico, isso aparece.

Oportunidade de mercado

O Mini Índice é um dos contratos mais negociados da B3. Tem liquidez alta durante todo o pregão, margem baixa e valor de **R$ 0,20 por ponto** (variação mínima de 5 pontos), o que permite operar com capital pequeno e dimensionar posição em passos finos. O índice brasileiro tem movimentos intradiários direcionais frequentes, que são o terreno de uma estratégia de tendência. A obrigação de zerar no fim do dia elimina o risco de gap noturno.

4.3 Descrição da estratégia

Fundamentos

A estratégia segue tendência e tem duas camadas. A **camada de regra** usa o sistema DMI de Wilder: **DI+ e DI−** dizem *para onde* (qual lado manda) e o **ADX** diz se há força. O **ATR** mede a volatilidade corrente e define o tamanho do stop e do alvo. A **camada de aprendizado** recebe cada sinal da regra e decide se ele vale a pena naquele contexto.

Indicadores técnicos

INDICADOR	USO NA REGRA	USO COMO VARIÁVEL DO MODELO
DI+ / DI− (12)	Lado dominante define compra ou venda	Diferença DI+ − DI−, no sentido da operação
ADX (12)	Filtro mínimo de força (ADX ≥ 20)	Nível e inclinação do ADX
ATR (14)	Escala stop, alvo e trava no zero a zero	ATR relativo ao preço e seu percentil recente
VWAP do dia	—	Distância do preço à VWAP, em ATRs

DMI 12 e ADX ≥ 20 ficam fixos. No Trabalho 01, o fator de lucro ficou entre 1,24 e 1,42 com o período do DMI variando de 8 a 20, então esse valor não é crítico. O limiar 20 é mais permissivo que o clássico 25 de propósito: a regra gera mais candidatos e a floresta faz a seleção fina.

Regras de entrada

Avaliadas apenas no fechamento de cada barra de 15 minutos, sobre barras já fechadas:

- **Candidato de compra:** DI+ > DI− e ADX ≥ 20 e ADX subindo em relação à barra anterior.
- **Candidato de venda:** DI− > DI+ e ADX ≥ 20 e ADX subindo em relação à barra anterior.
- **Filtro do modelo:** o robô entra somente se P(alvo antes do stop) ≥ p^*, onde P vem do Random Forest e p^* é escolhido na validação (seção 4.4).

- **Filtros operacionais:** horário entre 09:15 e 17:00, nenhuma posição aberta, limites diários não atingidos.

Regras de saída, com justificativa

SAÍDA	REGRA	JUSTIFICATIVA
Stop loss	1,5 × ATR a partir da entrada	Limita a perda a um múltiplo do ruído normal do mercado. Um stop fixo em pontos fica curto em dia volátil e largo em dia calmo.
Take profit	3,0 × ATR a partir da entrada	Relação 2:1 entre alvo e stop, próxima da usada no Trabalho 01 (375 / 150 pontos). Com ela, basta acertar mais de 1/3 das operações para cobrir as perdas antes dos custos.
Trava no zero a zero	Stop vai ao preço de entrada após 1,5 × ATR a favor	Impede que uma operação que já andou a favor vire perda. No Trabalho 01 a trava melhorou o modo de entrada por estado (1,26 → 1,34).
Fim do pregão	Zera tudo às 17:30	É day trade: não carrega posição para o dia seguinte, o que elimina o risco de gap noturno e a margem de custódia.

As mesmas regras de saída, inclusive a trava no zero a zero, definem o **rótulo** com que o modelo é treinado (seção 4.4). Assim o modelo aprende o mesmo evento que decide o resultado da operação real.

Gestão de risco e tamanho de posição

- **Toda ordem sai com stop e alvo** registrados na corretora no momento da entrada.
- **Tamanho por risco, modulado pela confiança do modelo:** o risco por operação é $R = 0{,}25\%$ do capital se $p^* \le P < 0{,}65$, e $R = 0{,}5\%$ se $P \ge 0{,}65$.

  ```
  contratos = max(1, min(5, ⌊ R × Capital / (1,5 × ATR × R$ 0,20) ⌋ ))
  ```

  Com capital de R$ 20.000, $R = 0{,}5\%$ e ATR de 140 pontos (stop de 210 pontos, R$ 42 por contrato): $\lfloor 100 / 42 \rfloor = 2$ contratos. Quando a volatilidade sobe o stop alarga e o número de contratos cai, então o risco em reais fica constante.
- **Trava diária:** no máximo 4 operações por dia. O robô para no dia após perder 1,5% do capital ou após 3 stops seguidos.
- **Uma posição por vez**, sem preço médio e sem aumentar posição perdedora.

4.4 Sistema de aprendizado de máquina

Técnica escolhida: Random Forest

O problema é de **classificação**: dado o contexto do mercado no momento de um sinal, a operação vai atingir o alvo antes do stop? O Random Forest (Breiman, 2001) é um conjunto de árvores de decisão, cada uma treinada numa amostra diferente dos dados e com um subconjunto aleatório das variáveis. A probabilidade final é a média das estimativas das árvores: cada folha guarda a proporção de exemplos do treino que bateram o alvo. Escolhemos a técnica por cinco motivos:

- **Funciona com poucos dados.** Seis meses geram algumas centenas de sinais. O Random Forest lida bem com esse tamanho. Uma rede LSTM precisaria de muito mais exemplos e tenderia a decorar

ruído.
- **Resiste ao sobreajuste.** A média de centenas de árvores diferentes reduz a variância de uma árvore isolada, e a profundidade limitada impede que cada árvore decore o treino.
- **Capta interações não lineares** entre variáveis sem que precisemos especificá-las, e dispensa normalização.
- **Treina em segundos.** Retreinar a cada janela não tem custo relevante. Um backtest por indivíduo, como num Algoritmo Genético, custaria horas por ciclo.
- **É interpretável e fácil de implementar.** A importância das variáveis mostra o que pesa na decisão. A implementação usa o `RandomForestClassifier` do scikit-learn, e o modelo pode ser exportado em ONNX para rodar dentro do MetaTrader 5.

As alternativas foram descartadas por motivos específicos. **Redes neurais (LSTM)** exigem muitos dados, são lentas de treinar, sensíveis a hiperparâmetros e opacas. O **Algoritmo Genético** otimiza parâmetros fixos, mas não olha o contexto de cada operação. A **Lógica Fuzzy** depende de funções de pertinência definidas à mão.

Variáveis de entrada (features)

Calculadas no fechamento da barra do sinal, só com informação disponível naquele instante. As variáveis de direção são multiplicadas pelo sentido da operação (+1 compra, −1 venda), para que "a favor" signifique o mesmo nos dois lados e um único modelo sirva para compra e venda.

GRUPO	VARIÁVEL
Tendência	ADX; inclinação do ADX em 3 barras; (DI+ − DI−) × sentido
Volatilidade	ATR / preço; percentil do ATR nos últimos 20 pregões; amplitude do dia até agora em ATRs
Momento	Retorno das últimas 1, 4 e 16 barras × sentido, em ATRs
Posição no dia	Distância à VWAP × sentido, em ATRs; posição do preço na máxima e mínima do dia (0 a 1); gap de abertura × sentido, em ATRs
Fluxo	Volume da barra ÷ média do mesmo horário nos últimos 20 pregões
Calendário	Minutos desde a abertura; dia da semana
Sinal	Sentido (+1/−1); operações já feitas no dia

Rótulo (o que o modelo aprende)

Cada sinal da regra base no histórico é simulado com as mesmas saídas da seção 4.3 (stop, alvo, trava no zero a zero e encerramento às 17:30), numa adaptação do método das três barreiras (López de Prado, 2018):

```
y = 1  se a operação sai no alvo (3,0 × ATR)
y = 0  se sai no stop (1,5 × ATR), na trava no zero a zero ou no encerramento
das 17:30
```

O que se pretende otimizar

- **A seleção das operações:** o modelo aprende a probabilidade *P*(y = 1 | contexto).

- **O limiar de entrada *p****, entre 0,40 e 0,70 em passos de 0,025: define quantos sinais passam pelo filtro.
- **Os hiperparâmetros** do Random Forest: profundidade máxima {3, 5, 8}, mínimo de amostras por folha {5, 10, 20} e fração de variáveis por divisão {√p, 0,5}. O número de árvores fica fixo em 300 e as classes são balanceadas por peso.

As regras de DMI/ADX e as saídas em ATR ficam fixas. Isso mantém o rótulo estável e evita otimizar a regra e o filtro ao mesmo tempo, o que multiplicaria o risco de sobreajuste.

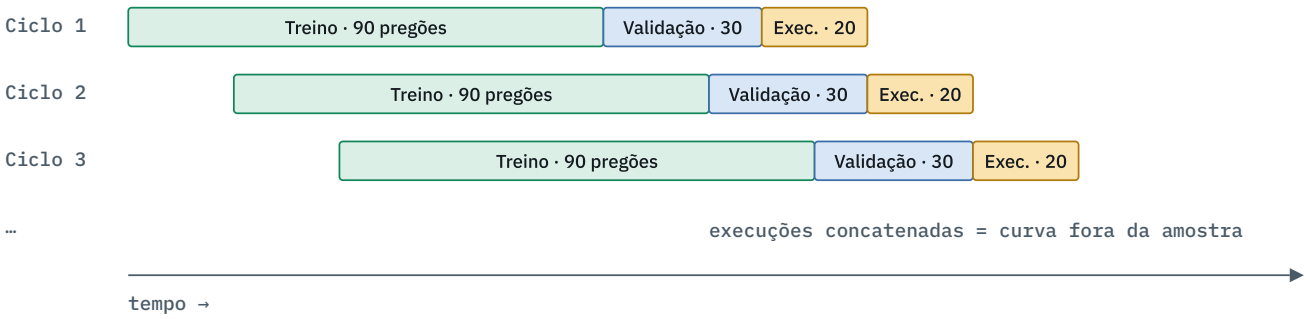
Função objetivo

São dois níveis. As **árvores** são construídas minimizando a impureza de Gini, o critério padrão de classificação. A **escolha de hiperparâmetros e limiar** não usa acurácia, porque acurácia alta não garante dinheiro. Ela usa o resultado financeiro das operações filtradas no trecho de validação, já com custos:

```
F(θ, p*) = LucroLíquido / RebaixamentoMáximo   (fator de recuperação)
sujeito a: N ≥ 20 operações e fator de lucro ≥ 1,05; se violar, F = −1
```

- **Fator de recuperação:** premia ganhar muito arriscando pouco. Maximizar só o lucro escolheria filtros que ganham com rebaixamentos insuportáveis.
- **N ≥ 20:** impede que o limiar suba tanto que sobrem três operações de sorte.
- **Custos:** R$ 0,50 por contrato por lado de emolumentos e corretagem, mais 1 tick (5 pontos) de derrapagem por lado. É uma premissa conservadora.
- **Métricas de acompanhamento**, que não decidem nada: AUC, precisão e a curva de calibração das probabilidades.

Arquitetura temporal: janela móvel (walk-forward)



Janela de treinamento de 120 pregões: os 90 primeiros ajustam o modelo e os 30 últimos escolhem hiperparâmetros e limiar. Depois o modelo é retreinado nos 120 pregões completos e opera nos 20 seguintes. Tudo avança 20 pregões e o ciclo se repete.

- **Janela de treinamento:** 120 pregões contínuos (cerca de 6 meses e algumas centenas de sinais). Os 90 primeiros treinam candidatos, e os 30 últimos, sempre posteriores, escolhem hiperparâmetros e *p** pela função objetivo. O modelo final é retreinado nos 120 pregões com a configuração vencedora.
- **Janela de execução:** os 20 pregões seguintes (cerca de 1 mês). O robô opera com o modelo congelado.
- **Deslocamento:** ao fim de cada execução, as janelas avançam 20 pregões e o modelo é retreinado. Na operação real isso acontece no fim de semana.

- **Período de estudo:** `WIN$` M15 de janeiro de 2023 a outubro de 2026, cerca de 940 pregões e **~40 ciclos** fora da amostra.

Restrições do problema

- **Operacionais:** apenas day trade, com tudo zerado às 17:30. Uma posição por vez. Toda ordem com stop e alvo. Máximo de 4 operações por dia.
- **Sem olhar o futuro:** as variáveis usam só barras fechadas. Validação sempre posterior ao treino, sem embaralhar a ordem temporal. A janela de execução nunca influencia o modelo.
- **Sem vazamento de rótulo:** toda operação simulada fecha até as 17:30 do mesmo pregão, então o rótulo de um sinal nunca usa dados de outro dia. Nenhum rótulo do treino depende de preços da validação ou da execução.
- **Estatísticas:** desbalanceamento de classes tratado por peso. Mínimo de 20 operações na validação para aceitar uma configuração.
- **Da série contínua:** o `WIN$` emenda contratos com vencimentos diferentes. Por ser day trade, nenhuma posição atravessa a rolagem, e as variáveis que dependem de vários dias são recalculadas a partir do novo contrato.

---

5 Avaliação e próximos passos

Como o resultado será medido

Só a curva **fora da amostra** (a concatenação das janelas de execução) conta como resultado. Ela será comparada com duas referências no mesmo período e com os mesmos custos:

1. **Regra sem filtro:** todos os sinais da regra base são operados. Essa comparação isola o valor do Random Forest.
2. **Cata-vento original:** o robô do Trabalho 01 com seus parâmetros fixos.

Métricas: lucro líquido, fator de lucro, rebaixamento máximo, fator de recuperação, taxa de acerto, número de operações e AUC fora da amostra. A hipótese se confirma se o filtro superar a regra sem filtro em fator de recuperação na maioria dos ciclos. Se não superar, isso também é um resultado e será relatado como tal.

Plano de implementação (próxima etapa)

1. Exportar as barras M15 do `WIN$` do MetaTrader 5 para CSV.
2. Em Python (pandas e scikit-learn): gerar os sinais da regra, calcular as variáveis e os rótulos, e rodar o laço walk-forward com treino, validação e execução.
3. Simular as operações filtradas com custos e gerar o relatório: curva fora da amostra, comparação com as referências e importância das variáveis ao longo dos ciclos.
4. Opcional: exportar o modelo em ONNX e carregá-lo num robô MQL5 para demonstrar a execução no Testador do MetaTrader 5.

---

6 Referências

- BREIMAN, Leo. Random Forests. *Machine Learning*, v. 45, n. 1, p. 5–32, 2001.
- LÓPEZ DE PRADO, Marcos. *Advances in Financial Machine Learning*. Hoboken: Wiley, 2018.

- WILDER, J. Welles. *New Concepts in Technical Trading Systems*. Greensboro: Trend Research, 1978.
- PARDO, Robert. *The Evaluation and Optimization of Trading Strategies*. 2. ed. Hoboken: Wiley, 2008.
- PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, v. 12, p. 2825–2830, 2011.
- B3. Contrato Futuro Mini de Ibovespa: especificações. Disponível em: b3.com.br.